洲江大学

课程名称: 操作系统

姓名: 何瑞桓 周琪东

学院: 竺可桢学院

专业: 计算机科学与技术

学号: 3190101928 3190106231

指导老师: 季江民

2021年11月16日

浙江大学实验报告

RV64 内核线程调度

一、实验内容

1. 准备工程

- 此次实验基于 lab2 同学所实现的代码进行。
- 从 repo 同步以下代码: rand.h/rand.c, string.h/string.c, mm.h/mm.c。并按照以下步骤将这些文件正确放置。其中 mm.h/mm.c 提供了简单的物理内存管理接口, rand.h/rand.c 提供了rand()接口用以提供伪随机数序列, string.h/string.c 提供了 memset 接口用以初始化一段内存空间。

```
.

├── arch

├── riscv

├── include

├── imm.h

├── kernel

├── include

├── include

├── rand.h

├── string.h

├── lib

├── rand.c

├── string.c
```

• 在 lab3 中我们需要一些物理内存管理的接口,在此我们提供了 kalloc 接口(见 mm.c)给同学。 同学可以用 kalloc 来申请 4KB 的物理页。由于引入了简单的物理内存管理,需要在 _start 的 适当位置调用 mm_init,来初始化内存管理系统,并且在初始化时需要用一些自定义的宏,需要修改 defs.h,在 defs.h 添加 如下内容:

• 在 arch/riscv/include 下添加 proc.h

```
// arch/riscv/include/proc.h

#include "types.h"

#define NR_TASKS (1 + 31) // 用于控制 最大线程数量 (idle 线程 + 31 内核线程)

#define TASK_RUNNING 0 // 为了简化实验,所有的线程都只有一种状态
```

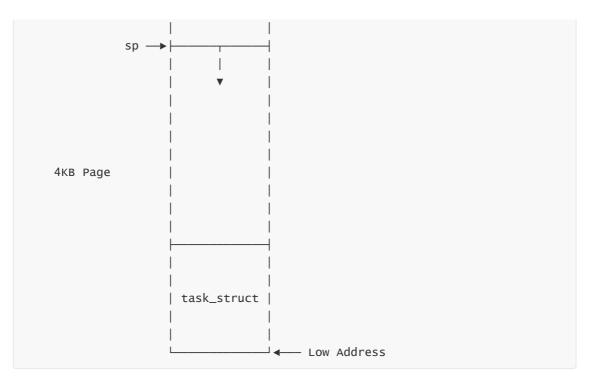
```
#define PRIORITY_MIN 1
#define PRIORITY_MAX 10
/* 用于记录 `线程` 的 `内核栈与用户栈指针` */
/* (1ab3中无需考虑,在这里引入是为了之后实验的使用) */
struct thread_info {
   uint64 kernel_sp;
   uint64 user_sp;
};
/* 线程状态段数据结构 */
struct thread_struct {
   uint64 ra;
   uint64 sp;
   uint64 s[12];
};
/* 线程数据结构 */
struct task_struct {
   struct thread_info* thread_info;
   uint64 state; // 线程状态
   uint64 counter; // 运行剩余时间
   uint64 priority; // 运行优先级 1最低 10最高
   uint64 pid; // 线程id
   struct thread_struct thread;
};
/* 线程初始化 创建 NR_TASKS 个线程 */
void task_init();
/* 在时钟中断处理中被调用 用于判断是否需要进行调度 */
void do_timer();
/* 调度程序 选择出下一个运行的线程 */
void schedule();
/* 线程切换入口函数*/
void switch_to(struct task_struct* next);
/* dummy funciton: 一个循环程序,循环输出自己的 pid 以及一个自增的局部变量*/
void dummy();
```

2. 线程调度功能

2.1 线程初始化

• 在初始化线程的时候,我们参考<u>Linux v0.11中的实现</u>为每个线程分配一个 4KB 的物理页,我们将 task_struct 存放在该页的低地址部分, 将线程的栈指针 sp 指向该页的高地址。具体内存布局 如下图所示:





- 当我们的 OS run 起来时候,其本身就是一个线程 idle 线程,但是我们并没有为它设计好 task_struct。所以第一步我们要为 idle 设置 task_struct。并将 current, task[0] 都指向 idle。
- 为了方便起见,我们将 task[1] ~ task[NR_TASKS 1],全部初始化,这里和 idle 设置的区别在于要为这些线程设置 thread_struct 中的 ra 和 sp.
- 在 _start 适当的位置调用 task_init 和 mm_init

```
void task_init() {
   // 1. 调用 kalloc() 为 idle 分配一个物理页
   idle = (struct task_struct *) kalloc();
   // 2. 设置 state 为 TASK_RUNNING;
   idle->state = TASK_RUNNING;
   // 3. 由于 idle 不参与调度 可以将其 counter / priority 设置为 0
   idle->counter = 0;
   idle->priority = 0;
   // 4. 设置 idle 的 pid 为 0
   idle->pid = 0;
   // 5. 将 current 和 task[0] 指向 idle
   current = idle;
   task[0] = idle;
   /* YOUR CODE HERE */
   // 1. 参考 idle 的设置,为 task[1] ~ task[NR_TASKS - 1] 进行初始化
   // 2. 其中每个线程的 state 为 TASK_RUNNING, counter 为 0, priority 使用 rand() 来
设置,pid 为该线程在线程数组中的下标。
   // 3. 为 task[1] ~ task[NR_TASKS - 1] 设置 `thread_struct` 中的 `ra` 和 `sp`,
   // 4. 其中 `ra` 设置为 __dummy (见 4.3.2) 的地址, `sp` 设置为 该线程申请的物理页的
高地址
   /* YOUR CODE HERE */
   for (int i = 1; i < NR_TASKS; ++i) {
       task[i] = (struct task_struct *) kalloc();
       task[i]->state = TASK_RUNNING;
       task[i]->counter = 0;
       task[i]->pid = i;
       task[i]->priority = rand();
       task[i]->thread.ra = (uint64) &__dummy;
```

```
task[i]->thread.sp = PGROUNDUP((uint64) task[i]);
}
printk("...proc_init done!\n");
}
```

```
# head.S
.extern start_kernel
   .section .text.init
   .globl _start
_start:
   # - your code here -
   # set stvec = _traps
   la sp, boot_stack
   la t0, _traps
   csrrw x0, stvec, t0
   # -----
   # set sie[STIE] = 1
   li t0, 0x00000020
   csrrs x0, sie, t0
   # set first time interrupt
   call mm_init
   call task_init
   call clock_set_next_event
   # set sstatus[SIE] = 1
   li t1, 0x00000002
   csrrs x0, sstatus, t1
   # -----
   # -----
   # - your lab1 code -
   # -----
   call start_kernel
   # -----
   .section .bss.stack
   .globl boot_stack
boot_stack:
   .space 4096 # <-- change to your stack size
   .globl boot_stack_top
boot_stack_top:
```

注意:要将lab1完成的 la sp, boot_stack 放在两个init前

2.2 __dummy 与 dummy 完成

• task[1] ~ task[NR_TASKS - 1] 都运行同一段代码 dummy() 我们在 proc.c 添加 dummy():

```
// arch/riscv/kernel/proc.c
int flag=0;
void dummy() {
   uint64 MOD = 1000000007;
   uint64 auto_inc_local_var = 0;
```

注:加入全局变量flag用于标志是否刚刚发生跳转。

- 当线程在运行时,由于时钟中断的触发,会将当前运行线程的上下文环境保存在栈上(lab2中实现的 __traps)。当线程再次被调度时,会将上下文从栈上恢复,但是当我们创建一个新的线程,此时线程的栈为空,当这个线程被调度时,是没有上下文需要被恢复的,所以我们需要为线程第一次调度提供一个特殊的返回函数 __dummy
- 在 entry.S 添加 __dummy
 - 在 __dummy 中将 sepc 设置为 dummy() 的地址, 并使用 sret 从中断中返回。
 - o __dummy 与 _traps 的 restore 部分相比,其实就是省略了从栈上恢复上下文的过程 (但是手动设置了 sepc)。

```
.globl __dummy
__dummy:
    la t0, dummy
    csrw sepc, t0
    sret
```

2.3 实现线程切换

• 判断下一个执行的线程 next 与当前的线程 current 是否为同一个线程,如果是同一个线程,则 无需做任何处理,否则调用 __switch_to 进行线程切换。

```
// arch/riscv/kernel/proc.c

extern void __switch_to(struct task_struct* prev, struct task_struct* next);

void switch_to(struct task_struct *next) {
    /* YOUR CODE HERE */
    if (current->pid != next->pid) {
        struct task_struct* temp;
        temp = current;
        current = next;
        __switch_to(temp, next);
        flag = 1;
    }
}
```

- 在 entry.s 中实现线程上下文切换 __switch_to:
 - __switch_to 接受两个 task_struct 指针作为参数

- o 保存当前线程的 ra, sp, s0~s11 到当前线程的 thread_struct 中
- 将下一个线程的 thread_struct 中的相关数据载入到 ra, sp, s0~s11 中。

```
# arch/riscv/kernel/entry.S
    .globl __switch_to
__switch_to:
   # save state to prev process
    # YOUR CODE HERE
   sd ra, 40(a0)
    sd sp, 48(a0)
    sd s0, 56(a0)
   sd s1, 64(a0)
   sd s2, 72(a0)
   sd s3, 80(a0)
   sd s4, 88(a0)
   sd s5, 96(a0)
   sd s6, 104(a0)
   sd s7, 112(a0)
   sd s8, 120(a0)
    sd s9, 128(a0)
   sd s10, 136(a0)
    sd s11, 144(a0)
   # restore state from next process
   # YOUR CODE HERE
   1d ra, 40(a1)
   1d sp, 48(a1)
   1d s0, 56(a1)
   ld s1, 64(a1)
   1d s2, 72(a1)
   1d s3, 80(a1)
   1d s4, 88(a1)
   ld s5, 96(a1)
   ld s6, 104(a1)
   ld s7, 112(a1)
   ld s8, 120(a1)
   1d s9, 128(a1)
   1d s10, 136(a1)
   ld s11, 144(a1)
    ret
```

2.4 实现调度入口函数

• 实现 do_timer(),并在 时钟中断处理函数 中调用。

```
// arch/riscv/kernel/proc.c

void do_timer(void) {
    /* 1. 如果当前线程是 idle 线程 直接进行调度 */
    /* 2. 如果当前线程不是 idle 对当前线程的运行剩余时间减 1
    若剩余时间任然大于0 则直接返回 否则进行调度 */
    /* YOUR CODE HERE */
    if (idle->pid == current->pid) {
        schedule();
    } else {
        current->counter--;
}
```

```
if (current->counter <= 0) {
        schedule();
    }
}</pre>
```

do_timer最好放在clock_set_next_event后。

2.5 实现线程调度

本次实验我们需要实现两种调度算法: 1.短作业优先调度算法, 2.优先级调度算法。

2.5.1 短作业优先调度算法

- 当需要进行调度时按照一下规则进行调度:
 - o 遍历线程指针数组 task (不包括 idle ,即 task [0]),在所有运行状态 (TASK_RUNNING) 下的线程运行剩余时间 最少 的线程作为下一个执行的线程。
 - 如果 所有 运行状态下的线程运行剩余时间都为0,则对 [task[1] ~ [task[NR_TASKS-1]] 的运行剩余时间重新赋值(使用 [rand()]),之后再重新进行调度。

```
// arch/riscv/kernel/proc.c
void schedule(void) {
    int shortest = 0;
    for (int i = 1; i < NR_TASKS; ++i) {
        if (task[i]->state == TASK_RUNNING)
            if ((task[i]->counter < task[shortest]->counter && task[i]-
>counter > 0) || task[shortest]->counter <= 0) {</pre>
                shortest = i;
            }
    if (task[shortest]->counter <= 0) {</pre>
        for (int i = 1; i < NR_TASKS; ++i) {
            task[i]->counter = rand();
            printk("SET [PID = %d COUNTER = %d]\n", i, task[i]->counter);
        }
        shortest = 0;
        for (int i = 1; i < NR_TASKS; ++i) {
            if (task[i]->state == TASK_RUNNING)
                if ((task[i]->counter < task[shortest]->counter &&
                      task[i]->counter > 0) ||
                     task[shortest]->counter <= 0) {</pre>
```

```
shortest = i;
}

}

printk("switch to [PID = %d COUNTER = %d]\n", shortest, task[shortest]-
>counter);
switch_to(task[shortest]);
}
```

2.5.2 优先级调度算法

• 参考 Linux v0.11 调度算法实现 实现。

```
// arch/riscv/kernel/proc.c
void schedule(void) {
   int i, next, c;
   while (1) {
        c = -1;
        next = 0;
        i = NR_TASKS;
        while (--i) {
            if (task[i]->state!=TASK_RUNNING)
                continue;
            if ((int)(task[i]->counter) > c) {
                c = task[i]->counter;
                next = i;
            }
        }
        if (c>0) break;
        for(i = 1; i < NR\_TASKS ; ++i) {
            if (task[i]->state == TASK_RUNNING) {
                (task[i])->counter = ((task[i])->counter >> 1) +
                                      (task[i])->priority;
                printk("SET [PID = %d COUNTER = %d]\n", i, task[i]-
>counter);
            }
        }
    printk("switch to [PID = %d COUNTER = %d]\n", next, task[next]-
>counter);
    switch_to(task[next]);
}
```

```
#### 2.5.3 调度算法切换
```

在 Makefile 中加入如下

```
CFLAG = ${CF} ${INCLUDE} -D DSJF -g
```

在两个调度算法前使用

```
#ifdef DSJF

//DSJF算法实现

#else

//DPRIORITY算法实现

#endif
```

默认调用 DSJF ,去掉 Makefile 中的 -D DSJF 就可以调用 DPRIORITY 算法

在 main.c 里添加

```
#ifdef DSJF
    printk("DSJF\n");
#else
    printk("DPRIORITY\n");
#endif
```

用于标注当前执行的调度算法。

3. 编译及测试

为了较好的体现实验效果,将线程数量降为 1+4

DSJF:

```
Platform Name : QEMU Virt Machine
Platform HART Features : RV64ACDFIMSU
Platform Max HARTS : 8
Current Hart : 0
Firmware Base : 0x80000000
Firmware Size : 120 KB
Runtime SBI Version : 0.2
```

DPRIORITY:

```
Platform Name : QEMU Virt Machine
Platform HART Features : RV64ACDFIMSU
Platform Max HARTs : 8
Current Hart : 0
Firmware Base : 0x80000000
Firmware Size : 120 KB
                                                                                                                                                                                                                                                                     : 0x80000000
: 120 KB
: 0.2
                Runtime SBI Version
          SET [PID = 1 COUNTER = 10]
SET [PID = 2 COUNTER = 10]
SET [PID = 3 COUNTER = 5]
SET [PID = 4 COUNTER = 2]
SWITCH TO [PID = 4 COUNTER = 2]
SWITCH TO [PID = 3 COUNTER = 5]
SET [PID = 4] is running, auto_inc_local_var = 1
[PID = 4] is running, auto_inc_local_var = 2
SWITCH TO [PID = 3 COUNTER = 5]
[PID = 3] is running, auto_inc_local_var = 2
[PID = 3] is running, auto_inc_local_var = 2
[PID = 3] is running, auto_inc_local_var = 2
[PID = 3] is running, auto_inc_local_var = 3
[PID = 3] is running, auto_inc_local_var = 4
[PID = 3] is running, auto_inc_local_var = 5
SWITCH TO [PID = 1 COUNTER = 10]
[PID = 1] is running, auto_inc_local_var = 2
[PID = 1] is running, auto_inc_local_var = 2
[PID = 1] is running, auto_inc_local_var = 4
[PID = 1] is running, auto_inc_local_var = 6
[PID = 1] is running, auto_inc_local_var = 6
[PID = 1] is running, auto_inc_local_var = 7
[PID = 1] is running, auto_inc_local_var = 7
[PID = 1] is running, auto_inc_local_var = 8
[PID = 1] is running, auto_inc_local_var = 9
[PID = 1] is running, auto_inc_local_var = 1
[PID = 2] is running, auto_inc_local_var = 1
[PID = 2] is running, auto_inc_local_var = 3
[PID = 2] is running, auto_inc_local_var = 6
[PID = 2] is running, auto_inc_local_var = 7
[PID = 2] is running, auto_inc_local_var = 10
[PID = 2] is running, auto_inc_local_var = 7
[PID = 2] is running, auto_inc_local_var = 10
[PID = 2] is running, auto_inc_local_var = 10
[PID = 2] is running, auto_inc_local_var = 10
[P
```

得到了想要实现的效果,将线程数改为1+31依然得到了理想的结果。

思考题

1. 在 RV64 中一共用 32 个通用寄存器, 为什么 context_switch 中只保存了14个?

答: context_switch 中需要保存 Callee-saved register,即非易失性寄存器,这13个寄存器 在调用的过程中需要由被调用者来保护,所以 context-swicth 需要对他们进行保存,除此之外还需 要更改ra的值来实现跳转,所以一共需要保存14个寄存器,其余寄存器为 caller-saved register 如果需要保护寄存器的值,需要由调用函数者将其存入栈中。

Register	ABI Name	Description	Saver
x0	zero	Hard-wired zero	_
x1	ra	Return address	Caller
x2	sp	Stack pointer	Callee
x3	gp	Global pointer	_
x4	tp	Thread pointer	—
x5-7	t0-2	Temporaries	Caller
x8	s0/fp	Saved register/frame pointer	Callee
x9	s1	Saved register	Callee
x10-11	a0-1	Function arguments/return values	Caller
x12-17	a2-7	Function arguments	Caller
x18-27	s2-11	Saved registers	Callee
x28-31	t3-6	Temporaries	Caller
f0-7	ft0-7	FP temporaries	Caller
f8-9	fs0-1	FP saved registers	Callee
f10-11	fa0-1	FP arguments/return values	Caller
f12-17	fa2-7	FP arguments	Caller
f18-27	fs2-11	FP saved registers	Callee
f28-31	ft8-11	FP temporaries	Caller

Table 18.2: RISC-V calling convention register usage.

- 2. 当线程第一次调用时,其 ra 所代表的返回点是 __dummy。那么在之后的线程调用中 context_switch 中,ra 保存/恢复的函数返回点是什么呢?请同学用gdb尝试追踪一次完整的 线程切换流程,并关注每一次 ra 的变换。
 - 答: context_switch 中每次被存入的 ra 值是 schedule 的末尾处的地址,即 schedule 调用 context_switch 处的地址,而被恢复的都是指向 __dummy 的地址。

三、心得体会

1. mm_init 放置位置

mm_init 会使用sp寄存器,所以应该在 mm_init 前为sp寄存器赋初值,否则会导致越界。

mm_init, task_init 最好放于 clock_set_next_event 前,虽然本次实验设置的时间是一秒比较长,但如果设置的时间比较短可能在完成init前发生时钟中断,所以应该在完成init后再设置时钟中断,而这样的设置和lab2的参考代码是不符合的,花了我比较长的时间来发现这一错误。

2. switch_to代码位置

```
void switch_to(struct task_struct *next) {
    /* YOUR CODE HERE */
    if (current->pid != next->pid) {
        struct task_struct* temp;
        temp = current;
        current = next;
        flag = 1;
        __switch_to(temp, next);
}
```

__swich_to函数并不会帮你设置后current和next的关系,所以需要你手动去设置,但 current = next; 这一句不能放在 __switch_to(temp, next); 后,因为在 __switch_to(temp, next); 处发生的 跳转并不会回到这里而是会直接进入 dummy 函数。

3. dummy 运行判断

实验给定的 dummy 是存在问题的,一般情况下不太常见,将 rand 修改为输出1~2之间的整数就会发现,对 counter=1 的线程,即使发生了跳转也会因为last_counter和counter相等而不会执行输出,所以添加了全局变量flag,在发生跳转时对flag赋真值,在flag为真时一定进行输出,解决了这一问题。

总结

感觉本次实验还是比较困难的,实验指导可能因为是新开设的实验,感觉蛮多地方其实并不完善,如果不从大体去思考和理解这个项目,只是盲目地按照给的指导去做就会出现很多问题。但做出来以后还是很有成就感的。